

SLIDE 1 | DÉFI BIOMÉDICAL & CONTEXTE

~45 sec

ENJEU

86 % des essais subissent des retards

majeurs de recrutement (coût : 0,6 à 8 M\$/jour).

VERROU

Base ClinicalTrials.gov (> 499 000 études) : données enfouies dans des PDF de 50 à 100 pages.

MISSION

Pipeline ETL intelligent et souverain pour extraire les critères en JSON médical en < 0,5s.

» « Remplacer 45 minutes de lecture manuelle par une analyse IA instantanée et fiable. »

SLIDE 2 | LE PROBLÈME & LE MVP APPLICATIF

~1 min 15

UI STREAMLIT

Recherche par pathologie (ex: cancer du poumon) en < 1s via API publique.

EXTRACTION GPU

Clic "Analyser" → inférence GPU ciblée en 2 à 4s (entités structurées).

CACHE SUPABASE

Table clinical_ner_cache renvoie la réponse en 0,1s à coût GPU nul.

CHATBOT RAG

Dialogue en langage naturel direct avec le texte du protocole.

SLIDE 3 & 4 | DÉMO PRODUIT & VIDÉO

~1 min 30

ONGLET 1 & 2

Insister sur le Cache Mémoire de Session (RAM Render) : le JSON brut des 82 études est gardé en mémoire, affichage immédiat de l'onglet 2 sans requête réseau.

ONGLET 3

Surlignage visuel des entités médicales et structuration JSON validée.

ONGLET 4

Poser une question clinique ouverte (RAG) avec citations d'extraits.

SLIDE 5 | ARCHITECTURE LOGIQUE CLOUD

~1 min 15

PAAS RENDER

Frontend Streamlit (Port 8501) alimenté par Webhook GitHub Auto-Deploy.

BAAS SUPABASE

PostgreSQL 15, extension pgvector (768D), table de cache et S3 pour PDF.

IAAS AWS EC2

Instance GPU g4dn.xlarge (NVIDIA T4), FastAPI (Port 8000), vLLM (75 tok/s).

MLFLOW (5000)

Model Registry LoRA, métriques en direct (latency_sec, cache_hit), traces.

SLIDE 6 | CIRCUIT DE DONNÉE & ETL HYBRIDE

~1 min 15

INGESTION

Plan A direct (si texte > 100 car.) vs Plan B scraping CDN avec Zone de Rejet (PDF corrompus isolés sans bloquer le pipeline).

TRANSFORMATION

BioBERT découpe en 512 tokens et sélectionne les Top-5 chunks (anti-Lost in the Middle). Qwen LoRA extrait le JSON sans bruit.

RESTITUTION

Affichage UI et alimentation du cache persistant PostgreSQL.

SLIDE 7 | BENCHMARK & VALIDATION SCIENTIFIQUE

~1 min 30

GOLD STANDARD

1 000 études CHIA (split 800 train / 200 test strict par NCT sans fuite).

SCORES

Précision à 63,0 % (+19 pts) et F1-score à 58,3 % (+20 pts) vs modèle brut.

DÉFENSE F1

L'accord inter-médecins humains n'est que de 60 à 70 % ! Le modèle atteint quasiment le consensus clinique humain.

SÉCURITÉ

Priorité Précision : 74,6% sur Drug, et 100% sur le médicament cible en RAG (zéro hallucination de molécule fictive).

SLIDE 8 | PERSPECTIVES & TRAJECTOIRE MLOPS LEAD

~1 min 15

CI/CD

GitHub Actions, PyTest, évaluation RAG via RAGAs, Docker Multi-Stage (< 300 Mo vs 1,5 Go).

CT & DRIFT

Surveillance du Concept Drift (Wasserstein > 0,08) et ré-entraînement LoRA incrémental.

FINOPS & HDS

Terraform IaC, script Auto-Kill Boto3 (extinction EC2 GPU), déploiement On-Premise.

⚡ 4 RÈGLES D'OR POUR L'ORAL DU JURY :

1. Différence Schémas : Slide 5 = Logique Cloud (où tournent les serveurs) | Slide 6 = Flux (comment voyage la donnée).

2. Chunks BioBERT : 5 chunks pour le NER (densité max) | 15 chunks pour le RAG (vision globale).

3. Exact Matching vs Span Overlap : L'Exact Matching sanctionne à 0,07 les sauts de ligne PDF ; le Span Overlap valide la justesse clinique.

4. MLflow en prod : Latences réelles, traces et Model Registry actifs (le drift Wasserstein est la perspective Slide 8).