

SLIDE 1 | TITRE & DÉFI BIOMÉDICAL

~45s

PROBLÉMATIQUE

Goulot d'étranglement mondial du recrutement

En oncologie, **86 % des essais subissent des retards majeurs** de recrutement, coûtant 0,6 à 8 M\$ par jour aux labos et centres de recherche.

VERROU TECHNIQUE

L'information vitale est enfouie et non structurée

Base officielle **ClinicalTrials.gov** (> 499 000 études) : les critères d'éligibilité sont coincés dans des JSON bruts indigestes ou des **PDF de 50 à 100 pages**.

MISSION CLINER

Extraction chirurgicale & Standardisation IA

Construire un pipeline ETL intelligent et souverain pour extraire les entités médicales clés et les restituer en **données JSON exploitables en < 0,5s**.

Phrase Clé :

« Transformer 45 minutes de lecture manuelle d'un médecin en une fraction de seconde d'IA fiable. »

SLIDE 2 | LE PROBLÈME & LE MVP APPLICATIF

~1m 15s

INTERFACE MÉDECIN

Application Streamlit Réactive

Le praticien saisit une pathologie (ex: *cancer du poumon*) : l'API publique est interrogée en < **1s** et affiche les essais disponibles.

INFÉRENCE GPU

Extraction ciblée à la demande

Clic sur "Analyser" : le GPU s'active pour extraire en **2 à 4s** le JSON structuré (maladies, molécules, tranches d'âge, exclusions).

CACHE INSTANTANÉ

Restitution en 0,1s sans GPU

Si le protocole a déjà été analysé, la table **clinical_ner_cache** sert la réponse en **0,1s à coût GPU nul** (économie financière majeure).

CHATBOT RAG

Dialogue conversationnel avec le protocole

Assistant interactif permettant au médecin de poser des questions ouvertes sur l'essai et d'obtenir des réponses vérifiées avec citations.

SLIDE 3 & 4 | DÉMO PRODUIT & VIDÉO

~1m 30s

ONGLET 1 & 2

Recherche & Table Synthétique

Montrer la recherche par pathologie et insister sur le **cache mémoire de session (RAM Render)** : le JSON des 82 études est stocké localement, l'onglet 2 s'affiche sans ré-émettre de requête réseau.

ONGLET 3

Extraction NER & Structuration Visuelle

Mettre en avant l'extraction normalisée des critères d'éligibilité et le surlignage des entités médicales validées.

ONGLET 4

Chatbot RAG en Action

Poser une question clinique (ex: critères cardiaques) et montrer la réponse instantanée sourcée sur les extraits du protocole.

SLIDE 5 | ARCHITECTURE LOGIQUE CLOUD

~1m 15s

GITOPS & PAAS

GitHub → Render (Streamlit UI)

Dépôt GitHub avec **Webhook d'Auto-Deploy** sur Render (PaaS) à chaque push sur main. Streamlit gère le Session State RAM pour l'onglet 2.

BAAS MANAGÉ

Supabase Cloud (PostgreSQL + pgvector)

Stockage vectoriel **pgvector (768D BioBERT)**, table de cache persistant **clinical_ner_cache** (hit 0,1s) et bucket S3 pour les PDF. Accès via Service Role Key (Zero Trust).

IAAS GPU DÉDIÉ

AWS EC2 g4dn.xlarge (NVIDIA T4)

Conteneur Docker avec **FastAPI (port 8000)**, moteur **vLLM (75 tok/s)** et adaptateur LoRA 4-bit (40 Mo). Allumé à la demande.

OBSERVABILITÉ

MLflow Tracking (Port 5000)

Model Registry LoRA, métriques en direct (latency_sec, cache_hit) et traces applicatives (spans RAG et NER).

SLIDE 6 | CIRCUIT DE LA DONNÉE & ETL HYBRIDE

~1m 15s

INGESTION

Plan A (Fast-Track) vs Plan B (Scraping CDN)

Plan A direct si critères textuels présents (> 100 car.). Plan B : téléchargement du PDF officiel vers Supabase S3 avec **Zone de Rejet** isolant les fichiers corrompus sans bloquer l'ETL.

TRANSFORMATION

Pipeline Hybride BioBERT + Qwen LoRA

BioBERT (768D) : Découpe en chunks de 512 tokens et sélectionne chirurgicalement les **Top-5 chunks** (évite l'effet *Lost in the Middle*).
Qwen 2.5 7B LoRA : Reçoit ce contexte épuré et génère le JSON médical strict.

CHARGEMENT

Double restitution

Alimentation instantanée du dashboard utilisateur et enrichissement de la base vectorielle persistante pour les requêtes futures.

SLIDE 7 | BENCHMARK & VALIDATION SCIENTIFIQUE

~1m 30s

GOLD STANDARD

Corpus CHIA (1 000 études cliniques)

Split strict 800 train / 200 test par identifiant NCT pour garantir **zéro fuite de données (Data Leakage)**.

RÉSULTAT CLÉ

Précision Médicale Maximisée à 63 % (+19 pts)

Surpassement net du modèle brut (44 % → **63 %**) et F1-score qui bondit de 38 % à **58,3 % (+20 pts)**.

DÉFENSE F1

Consensus inter-médecins humains (60 % à 70 %)

Expliquer au jury qu'entre experts humains, l'accord n'est que de 60-70%. Notre modèle se hisse quasiment au niveau du consensus médical !

RÉALITÉ CLINIQUE

Priorité absolue à la Précision

En santé, rater un terme secondaire est toléré, mais **halluciner un traitement inexistant est une faute grave**. Précision de 74,6% sur Drug et 100% sur la molécule cible de l'essai en RAG.

À Dire au Jury :

« Nous avons fait le choix délibéré de la sécurité clinique : zéro hallucination sur les traitements testés. »

SLIDE 8 | PERSPECTIVES & TRAJECTOIRE MLOPS LEAD

~1m 15s

AXE 01

Intégration Continue (CI/CD) & Quality Gate

Pipelines GitHub Actions, tests unitaires PyTest multi-niveaux, évaluation automatique RAG via **RAGAs**, et conteneurisation **Docker Multi-Stage** durcie (< 300 Mo vs 1,5 Go).

AXE 02

Continuous Training (CT) & Surveillance Drift

Détection statistique automatique du Concept Drift sur les distributions vectorielles BioBERT (**distance de Wasserstein > 0,08**) et ré-entraînement incrémental LoRA trimestriel.

AXE 03

FinOps, IaC & IA Souveraine

Infrastructure as Code **Terraform**, script **Auto-Kill Boto3** sur l'EC2 GPU dès inactivité, et déploiement **On-Premise hospitalier** certifié Hébergeur de Données de Santé (HDS / RGPD).

⚡ RÈGLES D'OR POUR L'ORAL DU JURY

JOUR J

• Postures clés :

Parler d'une voix posée, regarder la caméra/jury, ne JAMAIS lire ses notes.

• Différence Architectures :

- *Slide 5* : Logique Cloud (Où tournent les machines : PaaS, BaaS, IaaS).
- *Slide 6* : Fonctionnelle & Flux (Comment voyage la donnée).

• Nombre de chunks :

5 pour le NER (densité max), 15 pour le Chatbot (couverture globale).

• Exact Matching vs Span Overlap :

L'Exact matching sanctionne à 0,07 les sauts de ligne PDF. Le Span Overlap valide la justesse sémantique réelle.

• Ce qui tourne dans MLflow :

Latence, traces, cache hits, Model Registry LoRA (drift Wasserstein = perspective CT Slide 8).